

2차과제

2022170841 최정우

#1. 로지스틱 회귀모델을 구축하기 위한 데이터를 찾고 어떤 문제를 해결하기 위한 데이터인지 설명하시오.

> <https://www.kaggle.com/datasets/stephanmatzka/predictive-maintenance-dataset-ai4i-2020?resource=download>

Predictive Maintenance Dataset (AI4I 2020)을 사용해보자.

Y변수(target variable)가 continuous한 numerical 데이터가 아닌 discrete한 categorical 데이터셋임.

Y 변수가 0(정상) , 1(불량)인 predictive maintenance 데이터셋을 찾아보았다. (machine failure을 불량이라고 하겠음)

New data(X)를 통해 양품 여부를 predict하는 (multivariate) logistic regression model을 구축해보자. (더 나아가 세부 고장까지 고려해볼 수 있음)

Column 에 대한 description.

1. UID: unique identifier ranging from 1 to 10000
2. product ID: consisting of a letter L, M, or H for low (50% of all products), medium (30%) and high (20%) as product quality variants and a variant-specific serial number
3. type: just the product type L, M or H from column 2
4. air temperature [K]: generated using a random walk process later normalized to a standard deviation of 2 K around 300 K
5. process temperature [K]: generated using a random walk process normalized to a standard deviation of 1 K, added to the air temperature plus 10 K.
6. rotational speed [rpm]: calculated from a power of 2860 W, overlaid with a normally distributed noise
7. torque [Nm]: torque values are normally distributed around 40 Nm with a SD = 10 Nm and no negative values.
8. tool wear [min]: The quality variants H/M/L add 5/3/2 minutes of tool wear to the used tool in the process.

9. a 'machine failure' label that indicates, whether the machine has failed in this particular datapoint for any of the following failure modes are true.

-> machine failure에서 세부 고장 원인을 다시 분류한다.

1. tool wear failure (TWF): the tool will be replaced or fail at a randomly selected tool wear time between 200 - 240 mins (120 times in our dataset). At this point in time, the tool is replaced 69 times, and fails 51 times (randomly assigned).
2. heat dissipation failure (HDF): heat dissipation causes a process failure, if the difference between air- and process temperature is below 8.6 K and the tools rotational speed is below 1380 rpm. This is the case for 115 data points.
3. power failure (PWF): the product of torque and rotational speed (in rad/s) equals the power required for the process. If this power is below 3500 W or above 9000 W, the process fails, which is the case 95 times in our dataset.
4. overstrain failure (OSF): if the product of tool wear and torque exceeds 11,000 minNm for the L product variant (12,000 M, 13,000 H), the process fails due to overstrain. This is true for 98 datapoints.
5. random failures (RNF): each process has a chance of 0,1 % to fail regardless of its process parameters. This is the case for only 5 datapoints, less than could be expected for 10,000 datapoints in our dataset.

If at least one of the above failure modes is true, the process fails and the 'machine failure' label is set to 1. It is therefore not transparent to the machine learning method, which of the failure modes has caused the process to fail.

#2. 로지스틱 회귀모델 구축하고 해석하시오 (odd ratios 해석 반드시 포함).

Index)

- EDA

Missing value : x

Machine failure


0 96.61

1 3.39

(unbalanced) -> 뒤에서 해결해주자.

--- 세부 고장 모드별 발생 건수 ---

TWF	46
HDF	115
PWF	95
OSF	98
RNF	19



* Machine Failure을 Quality Type으로 나눠주기


예상 : most of failure occur from L

실제 : L/M/H 에서 골고루 나옴

L 235

M 83

H 21



다중공산성을 확인하기 위해 correlation heatmap 작성 => Air temperature과 Process temperature의 다중공산성이 확인됨 -> Air temperature이 공정과 연결되는 더 직접적인 variable 이므로 process temperature 제거

Air temperature ~ Tool wear과 Machine Failure의 correlation이 낮은 이유 : class imbalance!

● Preprocessing

No missing value, multicollinearity 반영완료(EDA단계에서 process temp 제거)

* Type을 encoding해 feature로 넣기 (L : 1, M : 2, H :3 으로 mapping)

* Scaling (magnitude 다른 variable들.. type은 scaling에서 제외)

● Model construction & evaluation

* class imbalance해결하기 위해 **class weight**을 이용해 balance 맞춰주자 (data loss나 interpolation없이 cross entropy를 이용해서 F(1)일 때의 penalty를 30배로 처리 => odd ratio 해석에 좋음

결과)

```
--- 🎯 분류 성능 평가 (Classification Report) ---
              precision    recall  f1-score   support

     0       0.99      0.81      0.89      1932
     1       0.13      0.81      0.23        68


 accuracy          0.81      2000
 macro avg         0.56      0.81      0.56      2000
 weighted avg      0.96      0.81      0.87      2000

 ▶ ROC-AUC Score: 0.8918
```

(imbalanced data이므로

로 accuracy 보다는 precision, recall, f1-score가 더 중요)

1 -> precision 0.13인데 ... confusion matrix 보면 False Alarm이 엄청 많은 공정임(제조 공정이므로 불량



을 줄여야 하는 conservative model)

따라서 실제 불량품 68개중 0.81의 probability로 불량을 잡아냈으므로 괜찮은 model임을 알 수 있다.

ODD Ratio)


--- 로지스틱 회귀 오즈비(Odds Ratio) 분석 결과 ---

	Feature	Coefficient	Odds Ratio
0	Torque [Nm]	2.303696	10.011118
1	Rotational speed [rpm]	1.612440	5.015031
2	Air temperature [K]	0.768659	2.156871
3	Tool wear [min]	0.764588	2.148108
4	Type	-0.263101	0.768664

Odd ratio 를 보면 machine failure에 Failure의 “진짜 원인”을 알 수 있다.

1. **Torque** : Torque가 1std(9.97 Nm) 증가할 때마다 불량 확률 10배 증가
2. **Rotational speed** : Rotatinal speed가 1std(179.28 rpm) 증가할 때마다 불량 확률 5배 증가
3. **Air temperature**: Air temperature가 1std(2.00 K) 증가할 때마다 불량 확률 2.1배 증가
4. **Tool wear** : Tool wear가 1std(63.65 min) 증가할때마다 불량 확률 2.1배 증가함
5. **Type** : Type이 1 단위 증가시 정상 대비 불량률의 확률이 0.76배 증가.

>visualizaton



INSIGHT)

1. 속도를 늘리기 위해 Torque와 rotational speed를 끌어올리는 공정을 지양해야한다. -> torque와 rotational speed의 UCL을 conservative하게 정해 UCL을 넘어갈시 interlock작동
+ 생산량을 급격히 늘리는 기존 공정의 개선 필요
2. 2K가 증가할때마다 불량 확률이 2배 늘어나는 온도에 취약한 공정이므로 냉각수/윤활유 공급 시스템 점검 + HVAC(공조 시스템)을 관리해 항온상태를 유지하자.
3. Tool wear 의 특성상 temp와 torque처럼 외부 요인에 따라 갑자기 튀는게 아니므로, predictive maintenance를 통해서 tool을 정비하자.
4. Type은 품질 등급이 높아질수록 불량확률이 줄어드므로 L Type 제조 monitoring을 더 엄격히 진행해야한다.


#3. 분류 Cut off 값 (디폴트=0.5)을 바꾸어 가며 예측정확도 계산하고 적절한 Cut off값을 제시해 보시오.

Cut - off값을 0.1 부터 0.05씩 늘려가며 최적 cut-off값을 observe해보자.

1. imbalanced data -> f1-score의 max값으로 cut-off 설정
2. failure에 대해 conservative하게 접근 시 recall값이 0.9 이상인 곳에서 cut-off 설정

--- 🌈 Cut-off 값 변화에 따른 성능 변화 ---

	Cut-off	Accuracy	Precision	Recall	F1-Score
0	0.10	0.3470	0.0482	0.9706	0.0918
1	0.15	0.4620	0.0579	0.9706	0.1093
2	0.20	0.5465	0.0671	0.9559	0.1254
3	0.25	0.6050	0.0753	0.9412	0.1394
4	0.30	0.6595	0.0853	0.9265	0.1561
5	0.35	0.7055	0.0936	0.8824	0.1693
6	0.40	0.7460	0.1029	0.8382	0.1833
7	0.45	0.7870	0.1208	0.8382	0.2111
8	0.50	0.8140	0.1329	0.8088	0.2282
9	0.55	0.8460	0.1512	0.7647	0.2524
10	0.60	0.8695	0.1706	0.7353	0.2770
11	0.65	0.8885	0.1888	0.6912	0.2965
12	0.70	0.9070	0.2136	0.6471	0.3212
13	0.75	0.9320	0.2763	0.6176	0.3818
14	0.80	0.9490	0.3396	0.5294	0.4138
15	0.85	0.9560	0.3649	0.3971	0.3803
16	0.90	0.9630	0.4286	0.2647	0.3273



1. F1 score는 cut-off 0.8일 때 maximum이 되므로 0.8을 cut-off 로 설정.
 2. recall은 cut-off가 0.3~0.4일때 0.9 선을 유지하므로 0.35을 cut-off 로 설정 => QC관점 이게 optimal 한 solution
- #4. 3개 이상의 클래스를 가지는 로지스틱 회귀 문제에서 특정 클래스로 분류될 확률을 구하시오.

$$p(y=j | x, \theta) = ? \quad j=1, 2, \dots, K$$

$$\frac{p(y=1)}{p(y=k)} = e^{x^T \theta_1}$$

$$\frac{p(y=2)}{p(y=k)} = e^{x^T \theta_2}$$

⋮

$$\frac{p(y=j)}{p(y=k)} = e^{x^T \theta_j}$$

⋮

$$\frac{p(y=k-1)}{p(y=k)} = e^{x^T \theta_{k-1}}$$

$$\frac{p(y=k)}{p(y=k)} = e^{x^T \theta_k} = 1$$

$$\frac{\sum_{j=1}^{k-1} p(y=j)}{p(y=k)} = \sum_{j=1}^{k-1} e^{x^T \theta_j}$$

$$\textcircled{+} \quad \frac{1 - p(y=k)}{p(y=k)} = \sum_{j=1}^{k-1} e^{x^T \theta_j}$$

$$p(y=k) = \frac{1}{1 + \sum_{j=1}^{k-1} e^{x^T \theta_j}}$$

$$\frac{p(y=j)}{p(y=k)} = e^{x^T \theta_j} \quad \textcircled{//}$$

$$p(y=k) = \frac{p(y=j)}{e^{x^T \theta_j}}$$

$$\Rightarrow \frac{p(y=j)}{e^{x^T \theta_j}} = \frac{1}{1 + \sum_{j=1}^{k-1} e^{x^T \theta_j}}$$

$$p(y=j) = \frac{e^{x^T \theta_j}}{1 + \sum_{j=1}^{k-1} e^{x^T \theta_j}}$$

$$= \frac{e^{x^T \theta_j}}{\sum_{j=1}^K e^{x^T \theta_j}}$$

softmax function $\rightarrow$

5. #5. 분류 문제에서 log likelihood function을 최대화하는 것이 왜 cross entropy를 최소화하는 것과 같은지 설명하시오.

(MLE) : $\frac{1}{N}$ observed data의 Likelihood를 Maximize? <Statistical>

binary) $y_i \rightarrow \begin{matrix} 0 \\ 1 \end{matrix}$ / $\hat{y}_i$ $\Rightarrow P(y_i | x_i) = \hat{y}_i^{y_i} (1 - \hat{y}_i)^{1-y_i}$

정답 (label) 예측 확률

Joint Likelihood: $L = \prod_{i=1}^N P(y_i | x_i) \xrightarrow{\text{log transform}} \log L = \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1-y_i) \log(1-\hat{y}_i)]$

maximize

(Cross Entropy) <M.L. Loss Function>

$\min \left(\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1-y_i) \log(1-\hat{y}_i)] \right) \Rightarrow - \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1-y_i) \log(1-\hat{y}_i)]$

정답 p 예측 q minimize "Θ"